



教育经历

安徽大学 (211)

计算机科学与技术

硕士

• 硕士生导师: 许柯 (神经网络模型压缩、嵌入式 AI 系统及部署、生成式大模型优化)

南昌大学 (211)

信息与计算科学

本科

学术论文和专利

- Xu Ke, Ma T, Wang X, et al. **EQ-GPTQ: Towards Finetuning-Free Elastic Precision Quantization for Transformers**. *IEEE Transactions on Emerging Topics in Computational Intelligence*, 2026. (目前在投, 中科院二区, CCF-B, 除导师外一作)
- Xu Ke, Ma T, Shen X, et al. **PEQuant: Prompt-Driven Activation Reconstruction for Elastic Quantization of Vision Transformers**. *ACM International Conference on Multimedia*, 2026. (Accepted (oral), CCF-A, 除导师外一作)
- Ma T, Shen X, Xu Ke, et al. **CoDrift: Mitigating Compensation Drift in Reconstruction-Based LLM Pruning at High Sparsity**. *ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 2027. (目前在投, 一轮审稿均分 2.5/4, CCF-A, 本人一作导师通讯)
- Ma T, Wang J, Xu Ke, et al. **EP-GPT: Nested Weight Slices for Storage-Efficient Multi-Sparsity Pruning of LLMs**. (DAC 2027 待投, CCF-A, 本人一作导师通讯)
- Xu Ke, Yang L, Ma T, et al. **PRISMQ: NOISE-AWARE RESOURCE ALLOCATION FOR ELASTIC POST-TRAINING QUANTIZATION**. *International Conference on Learning Representations*, 2027. (目前在投, CCF-A, 除导师外二作)
- 许柯, 马天宇, 何兴华, 一种弹性精度量化的双模式激活叠加提示补偿方法及装置, 2026 (专利预审中, 除导师外一作)

科研经历

研究方向: 模型压缩 (弹性量化, 剪枝), 计算机视觉, 模型微调

■ 1: 面向 Training-free 的 Transformer 架构的弹性精度量化

针对现有量化方法通常仅针对单一比特宽度优化、导致部署时比特宽度不匹配时性能下降。本文提出了 EQ-GPTQ, 一种面向 Transformer 模型的无需微调的弹性精度后训练量化框架, 在 GPTQ/GPTAQ 基础上, 引入了基于相似性与跨层重要性的 token 级激活融合策略和基于相似性与 Hessian 感知的列级权重融合机制, 通过单次校准即可生成一组模型权重, 支持任意精度配置, 同时兼容混合精度部署。

■ 2: 用于视觉变换器弹性量化的提示驱动激活重构

针对现有弹性量化方法主要聚焦于权重空间重建、忽视激活端误差补偿的问题, 本文提出了 PEQuant, 一个面向视觉 Transformer 模型的提示驱动的弹性精度后训练量化框架, 创新性地将误差重建从权重空间转移到每个 Transformer 块的输入激活端, 通过堆叠低秩加法 Prompt 在不增加序列长度的前提下实现高效的激活级重建; 同时设计伪影吸收扩展 Prompt 作为注意力偏置, 抑制低比特量化下难以处理的激活异常值和高范数伪影, 并采用级联 LoRA 参数化与多精度激活融合策略, 实现高比特分支引导低比特 Prompt 学习、避免跨比特干扰的鲁棒联合校准。

■ 3: 一种针对大语言模型的权重激活双稀疏的 Training-free 的剪枝方法

旨在解决现有方法 (如 SparseGPT 和 DuoGPT) 在逐列迭代剪枝时因权重漂移导致优化目标偏离原始全精度模型的问题。通过将重建目标锚定到原始全精度输出而非当前补偿后的模型状态, 并设计基于列残差代理与补偿矩阵的高效算法, 同时引入基于剪枝损失的重要性重排序全局剪枝策略, 优先处理敏感列。在大语言模型剪枝中实现了很好的性能。

■ 4: 基于嵌套权重切片的存储高效大语言模型多稀疏率剪枝

提出一种基于嵌套权重切片的多剪枝率框架: 仅需一次校准, 通过渐进式剪枝构造嵌套掩码, 并将权重组织为共享核心和增量切片, 以支持推理时按需加载。针对误差补偿导致的共享权重不一致问题, 进一步设计切片一致性重构机制, 附加一些软硬协同设计, 适应边缘设备推理。

未来研究兴趣

- 模型压缩: 量化、剪枝、稀疏和蒸馏
- 模型部署、推理优化、硬件加速
- 模型高效微调

学术服务

- 项目申请书撰写: 协助导师完成国家自然科学基金面上项目申请书撰写。
- 协助审稿: 协助导师审阅 *ICLR*, *CVPR*, *IJCAI*, *ICML*, *SIGKDD*, *ACM MM*, *AAAI* 和 *IEEE TCSVT* 等会议期刊稿件。

奖项和证书

- 安徽大学人工智能学院特等奖学金
- 大学生英语 CET-6